

GKG 系统设计文档

全球新闻语义分析与主题追踪平台

系统设计文档

项目名称	GKG 全球新闻语义分析与主题追踪平台
课程名称	Java 程序设计
团队规模	2 人
技术栈	Java 17 + Swing + SQLite + JFreeChart + Weka
文档版本	v1.0
编写日期	2026-06-09

一、需求分析

1.1 项目背景

GDELT 2.0 Knowledge Graph (GKG) 每 15 分钟从全球新闻媒体中自动抽取人物、组织、地点、主题、情感、引语、行为等结构化信息。本项目基于一段时间（建议 1~7 天）的 GKG 数据，开发一套 Java 桌面应用，对外提供数据导入、语义查询、共现网络、主题追踪、情感与聚类分析、可视化展示等能力，帮助用户快速回答“谁在什么时候因为什么被报道、情感倾向如何”等问题。

1.2 功能需求

1.2.1 功能清单（覆盖任务书必做项 17 项 + 选做 2 项）

模块	编号	功能	优先级
数据管理	F-01	GKG CSV/TSV 单/批导入，含进度条	必做
数据管理	F-02	关系型表存储人物/组织/主题/情感/地点/引语	必做
数据管理	F-03	空值/重复/无效主题清理	必做
数据管理	F-04	查询/分析结果导出 CSV/Excel/JSON	必做
查询检索	F-06	日期+主题+人物+组织+地点组合查询	必做
查询检索	F-07	人物档案查询（频次、关联、情感）	必做
查询检索	F-08	组织档案查询	必做
查询检索	F-09	主题追踪（时间分布+情感变化）	必做
挖掘分析	F-12	人物-人物 / 人物-组织 共现网络	必做
挖掘分析	F-13	PageRank 识别焦点人物	必做
挖掘分析	F-14	主题热度排行（日/周/月）	必做
挖掘分析	F-15	TF-IDF + K-Means 主题聚类	必做
挖掘分析	F-16	V2Tone 情感趋势与拐点	必做
可视化	F-20	共现网络图（节点大小=PageRank）	必做
可视化	F-21	主题趋势折线图	必做
可视化	F-22	主题×月份热力图	必做
可视化	F-23	情感仪表盘 / 雷达图	必做
选做	F-10	名称模糊搜索 + 自动补全	选做（计划完成）
选做	F-24	引语展示墙（情感着色）	选做（计划完成）

1.2.2 用例图（文字描述）



主用例之间的关系:

- ③ ④ ⑤ «include» ① (查询/档案都依赖数据已入库)
- ⑥ ⑦ ⑧ «include» ①
- ⑨ «include» ⑥ ⑦ ⑧
- ⑩ «extend» ③ ④ ⑤ ⑦ ⑧ (任意结果界面可触发导出)

1.3 非功能需求


编号	维度	指标
NF-01	性能	5 万条 GKG 数据导入 ≤ 3 min (批量事务 + 预编译)；查询响应 ≤ 3 s；网络图渲染 ≤ 5 s
NF-02	兼容性	Windows 10/11 + JRE 17+，单 JAR 直接运行，免安装
NF-03	可用性	主操作有进度反馈，错误有明确弹窗提示；首次启动自动创建数据库
NF-04	健壮性	异常行（字段缺失、分隔符错乱）跳过并写入 <code>import_error.log</code> ，不中断主流程
NF-05	可扩展性	严格 MVC 三层 + DAO/Service/Controller/View 包；新增图表或查询条件仅需扩展 Service + UI
NF-06	代码规范	包/类/方法符合 Google Java Style；核心方法 JavaDoc 注释
NF-07	安全性	所有 SQL 使用 <code>PreparedStatement</code> ，防 SQL 注入

二、架构设计

2.1 技术栈选型

层次	选型	选择理由
语言 / JDK	Java 17 (LTS)	任务书强制要求，长期支持
构建工具	Maven 3.9	依赖管理 + <code>maven-shade-plugin</code> 一键打 fat-jar
GUI 框架	Swing + FlatLaf	无模块化打包问题；FlatLaf 提供现代外观
数据库	SQLite 3 (<code>xerial sqlite-jdbc</code>)	单文件、零部署、嵌入式
连接池	HikariCP	高性能；导入时复用连接
CSV/TSV 解析	OpenCSV	支持自定义分隔符 (<code>\t</code>)
图表	JFreeChart	折线图、柱状图、热力图、仪表盘均原生支持
网络图	自绘 <code>JPanel</code> + 力导向布局；算法用 JUNG	既显示又能跑 PageRank
文本挖掘	Weka 3.8 (<code>StringToWordVector</code> + <code>SimpleKMeans</code>)	现成 TF-IDF 与 K-Means
Excel/JSON	Apache POI 5 + Jackson 2	业界标准
日志	SLF4J + Logback	异常排查方便
测试	JUnit 5	仅对解析与算法做单元测试

2.2 系统体系结构 (MVC 三层)



2.3 项目包结构

```
gkg-platform/
├─ pom.xml
├─ README.md
├─ data/          # 示例 GKG 数据（已解压 .csv）
├─ db/            # 运行时生成的 gkg.db（gitignore）
├─ logs/
└─ src/main/
    ├─ java/edu/gkg/
    │   ├─ App.java          # 程序入口（main）
    │   └─ common/
    │       ├─ DbHelper.java  # HikariCP 数据源、建表 SQL
    │       ├─ AppConfig.java # 读取 config.properties
    │       └─ Constants.java
    │   └─ model/            # 实体类（POJO）
    │       ├─ GkgRecord.java
    │       ├─ Person.java
    │       ├─ Organization.java
    │       ├─ Theme.java
    │       ├─ Location.java
    │       ├─ Quote.java
    │       ├─ ToneScore.java
    │       └─ CooccurEdge.java
    │   └─ dao/
    │       ├─ GkgRecordDao.java
    │       ├─ PersonDao.java
    │       ├─ OrganizationDao.java
    │       ├─ ThemeDao.java
    │       ├─ LocationDao.java
    │       └─ QuoteDao.java
    │   └─ service/
    │       ├─ ImportService.java # F-01,F-02,F-03,F-05
    │       ├─ QueryService.java  # F-06,F-07,F-08,F-09,F-10
    │       ├─ AnalysisService.java # F-12,F-13,F-14,F-15,F-16
    │       └─ ExportService.java  # F-04
    │   └─ algorithm/
    │       ├─ CooccurrenceBuilder.java # F-12
    │       ├─ PageRankRunner.java      # F-13（基于 JUNG）
    │       ├─ ThemeRanker.java         # F-14
    │       ├─ KMeansClusterer.java     # F-15（基于 Weka）
    │       └─ SentimentTrend.java      # F-16
    │   └─ controller/
    │       ├─ ImportController.java
    │       ├─ QueryController.java
    │       └─ AnalysisController.java
    └─ view/
```

```

├── MainFrame.java
├── ImportPanel.java
├── QueryPanel.java
├── AnalysisPanel.java
├── QuoteWallPanel.java      # F-24
├── chart/
│   ├── CooccurNetworkPanel.java  # F-20
│   ├── TrendLineChart.java      # F-21
│   ├── ThemeHeatmap.java        # F-22
│   └── SentimentDashboard.java    # F-23
├── resources/
│   ├── config.properties
│   ├── schema.sql             # 建表 DDL
│   └── icons/

```


三、数据库设计

3.1 E-R 关系 (文字描述)

实体 (强类型) : - **GkgRecord**: 一条 GKG 新闻语义记录 (PK: `record_id`) - **Person**: 人物 (PK: `person_id`, UK: `name`) - **Organization**: 组织 (PK: `org_id`, UK: `name`) - **Theme**: 主题代码 (PK: `theme_id`, UK: `code`, 如 `SANCTIONS`) - **Location**: 地点 (PK: `location_id`, UK: `name` + `country_code`) - **Quote**: 引语 (PK: `quote_id`, FK: `record_id`)

关联 (M:N 通过中间表) : - GkgRecord — Person (中间表 `record_person`) - GkgRecord — Organization (中间表 `record_organization`) - GkgRecord — Theme (中间表 `record_theme`) - GkgRecord — Location (中间表 `record_location`)

派生 (分析结果缓存表) : - **Cooccurrence**: 人物/组织共现统计 (PK: `e1_id`, `e1_type`, `e2_id`, `e2_type`)



3.2 核心数据表结构

3.2.1 主记录表 `gkg_record`

字段	类型	约束	含义
record_id	TEXT	PK	GKG GKGRECORDID (形如 20240101000000-T1)
publish_date	TEXT	NOT NULL, INDEX	发布时间 (YYYY-MM-DD HH:mm)
source_collection	INTEGER		来源集合 ID
source_common_name	TEXT		媒体名称 (如 cnn.com)
document_id	TEXT		文章 URL
tone	REAL		V2Tone 总情感分 (-100~+100)
positive_score	REAL		正面得分
negative_score	REAL		负面得分
polarity	REAL		极性
word_count	INTEGER		词数

3.2.2 实体表

`person(person_id INTEGER PK AUTOINCREMENT, name TEXT UNIQUE NOT NULL)` `organization(org_id INTEGER PK AUTOINCREMENT, name TEXT UNIQUE NOT NULL)` `theme(theme_id INTEGER PK AUTOINCREMENT, code TEXT UNIQUE NOT NULL)` `location(location_id INTEGER PK AUTOINCREMENT, name TEXT, country_code TEXT, lat REAL, lng REAL, UNIQUE(name, country_code))`

3.2.3 关联表

表	字段
record_person	record_id TEXT FK, person_id INT FK, char_offset INT, PK(record_id, person_id)
record_organization	record_id TEXT FK, org_id INT FK, char_offset INT, PK(record_id, org_id)
record_theme	record_id TEXT FK, theme_id INT FK, char_offset INT, PK(record_id, theme_id)
record_location	record_id TEXT FK, location_id INT FK, char_offset INT, PK(record_id, location_id)

3.2.4 引语表 `quote`

字段	类型	约束
quote_id	INTEGER	PK AUTOINCREMENT
record_id	TEXT	FK → gkg_record.record_id
char_offset	INTEGER	
length	INTEGER	
verb	TEXT	引导词 (said / claimed)
content	TEXT	引语原文
sentiment	INTEGER	-1 负 / 0 中 / 1 正 (F-18 用, 可空)

3.2.5 共现缓存表 `cooccurrence`

字段	类型	含义
e1_id	INTEGER	节点 1 id
e1_type	TEXT	<code>PERSON</code> / <code>ORG</code>
e2_id	INTEGER	节点 2 id
e2_type	TEXT	<code>PERSON</code> / <code>ORG</code>
co_count	INTEGER	共同出现新闻数
PK	(e1_id, e1_type, e2_id, e2_type)	

3.2.6 索引策略

```
CREATE INDEX idx_gkg_date      ON gkg_record(publish_date);
CREATE INDEX idx_rp_person    ON record_person(person_id);
CREATE INDEX idx_ro_org       ON record_organization(org_id);
CREATE INDEX idx_rt_theme     ON record_theme(theme_id);
CREATE INDEX idx_quote_record ON quote(record_id);
```

四、模块说明

4.1 模块划分总览

序号	模块	主要类	对应需求
M1	数据接入	ImportService 、 GkgLineParser	F-01 / F-02 / F-03 / F-05
M2	持久化	DbHelper + 所有 *Dao	F-02
M3	查询	QueryService	F-06 / F-07 / F-08 / F-09 / F-10
M4	分析	AnalysisService + algorithm/*	F-12 ~ F-16
M5	导出	ExportService	F-04
M6	控制器	*Controller	联动 View 与 Service
M7	主界面	MainFrame + *Panel	F-01 / F-04 / F-06 ~ F-09 入口
M8	可视化	chart/*	F-20 / F-21 / F-22 / F-23 / F-24

4.2 核心接口设计

以下方法签名将作为 A、B 两位成员之间的协作契约，不得擅自变更。

4.2.1 ImportService (B 负责)

```

public interface ImportService {
    /** 导入单个 GKG csv 文件 */
    ImportResult importFile(File csvFile, ProgressListener listener);

    /** 批量导入目录 */
    ImportResult importDirectory(File dir, ProgressListener listener);

    /** 清理无效数据, 返回清理统计 */
    CleanResult cleanInvalidData();
}

public record ImportResult(int total, int success, int skipped, long elapsedMs) {}
public record CleanResult(int duplicateRemoved, int nullThemeRemoved, int
    invalidRowRemoved) {}

@FunctionalInterface
public interface ProgressListener {
    /** progress: 0~100, message: 当前阶段说明 */
    void onProgress(int progress, String message);
}

```

4.2.2 QueryService (A 负责实现, 接口由 B 在 W2 未交付)

```

public interface QueryService {
    /** F-06 组合查询, 分页 */
    Page<GkgRecord> search(QueryCondition cond, int page, int pageSize);

    /** F-07 人物档案 */
    PersonProfile getPersonProfile(String personName);

    /** F-08 组织档案 */
    OrgProfile getOrgProfile(String orgName);

    /** F-09 主题追踪: 日期 -> 频次、平均情感 */
    ThemeTrend getThemeTrend(String themeCode, LocalDate from, LocalDate to);

    /** F-10 模糊搜索 (前缀) */
    List<String> suggestPerson(String prefix, int limit);
    List<String> suggestOrg(String prefix, int limit);
}

```

4.2.3 AnalysisService (B 负责装配 Impl; 其中 F-13 PageRank 与 F-16 情感分析的算法类由 A 实现并交付)

```

public interface AnalysisService {
    /** F-12 构建/刷新共现网络 */
    void rebuildCooccurrence();

    /** F-13 PageRank Top-N 焦点 */
    List<FocusNode> topFocusPersons(int topN);

    /** F-14 主题热度 */
    List<ThemeHeat> themeHeatRank(Granularity g, LocalDate from, LocalDate to, int topN);

    /** F-15 K-Means 主题聚类 */
    List<Cluster> clusterByKMeans(int k, int maxIter);

    /** F-16 情感趋势 */
    SentimentSeries sentimentTrend(EntityRef ref, LocalDate from, LocalDate to);
}

```

4.2.4 ExportService (A 负责)

```

public interface ExportService {
    void exportCsv(List<?> rows, File target);
    void exportExcel(List<?> rows, File target);
    void exportJson(Object data, File target);
}

```

4.2.5 视图与控制器 (A 负责)

```

public class ImportController {
    public ImportController(ImportService importService, ImportPanel view) { ... }
    public void onImportButton(File file); // 异步 SwingWorker 调用 service
}

public class QueryController {
    public QueryController(QueryService queryService, QueryPanel view) { ... }
    public void onSearch(QueryCondition cond);
}


public class AnalysisController {
    public AnalysisController(AnalysisService analysisService, AnalysisPanel view) { ... }

    public void onShowFocusNetwork();
    public void onShowThemeTrend(String themeCode, LocalDate from, LocalDate to);
    public void onShowSentimentDashboard(EntityRef ref);
}

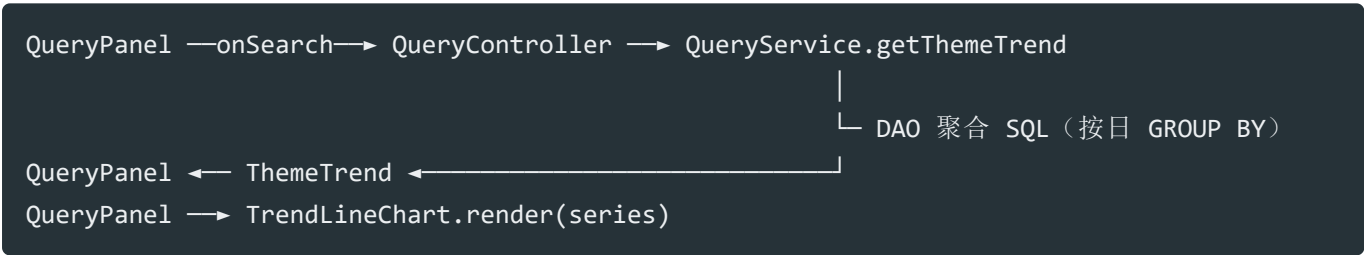
```

4.3 关键流程时序

4.3.1 数据导入 (F-01)



4.3.2 主题趋势查询 (F-09 + F-21)



4.4 部署与运行

```
# 构建
mvn clean package -DskipTests
# 运行
java -jar target/gkg-platform-1.0.0-shaded.jar
# 首次运行自动在 ./db/ 下创建 gkg.db 并执行 schema.sql
```

附录 A：风险与控制

风险	控制措施
大文件导入 OOM	按行流式解析 + 每 1000 条一次 <code>commit</code>
共现矩阵爆炸	仅统计同一新闻内 Top-K 个人物, K=20
K-Means 收敛慢	限制最大迭代 50, 文档数 > 1 万则先抽样
中文/特殊字符	文件统一 UTF-8 读写; JFreeChart 字体设为「微软雅黑」
单元测试覆盖	仅对 <code>GkgLineParser</code> 与 <code>PageRankRunner</code> 做核心断言